

Reglas de Agrupación de Datos Numéricos

In [1]: `import numpy as np`
`import pandas as pd`

In [2]: `def raiz(data):`
 `n = len(data)`
 `k1 = int(np.ceil(np.sqrt(n)))`
 `return k1`

`def sturges(data):`
 `n = len(data)`
 `k2 = int(np.ceil(1 + np.log2(n)))`
 `return k2`

`def scott(data):`
 `n = len(data)`
 `As = 3.5*np.std(data)*n**(-1/3)`
 `k3 = int(np.ceil((max(data)-min(data))/As))`
 `return k3`

`def freedman_diaconis(data):`
 `n = len(data)`
 `irq = np.percentile(data, 75) - np.percentile(data, 25)`
 `Afd = 2 * irq * np.power(n, -1/3)`
 `k4 = int(np.ceil((max(data)-min(data) / Afd)))`
 `return k4`

Cargamos el dataset:

In [3]: `crabs = pd.read_table("../data/datacrab.txt", sep = " ")`
`cw = np.array(crabs["width"])`

Pregunta 1

Da el algoritmo para reproducir el proceso de generación de clases y sus marcas donde el número de clases ha sido obtenido con la regla de la Scott en Python .

In [4]: `# Cálculo de la amplitud`
`A = round((max(cw)-min(cw))/scott(cw), 1)`

`print("La amplitud es {}".format(A))`

`# Extremos de los intervalos`
`L = np.zeros(scott(cw) + 1)`
`L[0] = min(cw) - 1 / 2 * 0.1`
`for i in range(1, scott(cw) + 1):`
 `L[i] = L[0] + i * A`

`print("Los intervalos son: {}".format(L))`
`# Marcas de clase`

`X = np.zeros(scott(cw))`
`X[0] = (L[0] + L[1])/2`
`for i in range(1, scott(cw)):`
 `X[i] = (L[i] + L[i+1])/2`

`print("Las marcas son: {}".format(X))`

La amplitud es 1.2

Los intervalos son: [20.95 22.15 23.35 24.55 25.75 26.95 28.15 29.35 30.55 31.75 32.95]

Las marcas son: [21.55 22.75 23.95 25.15 26.35 27.55 28.75 29.95 31.15 32.35]

Pregunta 2

Da el algoritmo para reproducir el proceso de generación de clases y sus marcas donde el número de clases ha sido obtenido con la regla de la raíz en Python .

In [5]: `# Cálculo de la amplitud`
`A = round((max(cw)-min(cw))/raiz(cw), 1)`

`print("La amplitud es {}".format(A))`

`# Extremos de los intervalos`
`L = np.zeros(raiz(cw) + 1)`
`L[0] = min(cw) - 1 / 2 * 0.1`
`for i in range(1, raiz(cw) + 1):`
 `L[i] = L[0] + i * A`

`print("Los intervalos son: {}".format(L))`
`# Marcas de clase`

`X = np.zeros(raiz(cw))`
`X[0] = (L[0] + L[1])/2`
`for i in range(1, raiz(cw)):`
 `X[i] = (L[i] + L[i+1])/2`

`print("Las marcas son: {}".format(X))`

La amplitud es 0.9

Los intervalos son: [20.95 21.85 22.75 23.65 24.55 25.45 26.35 27.25 28.15 29.05 29.95 30.85 31.75 32.65 33.55]

Las marcas son: [21.4 22.3 23.2 24.1 25. 25.9 26.8 27.7 28.6 29.5 30.4 31.3 32.2 33.1]

Pregunta 3

Da el algoritmo para reproducir el proceso de generación de clases y sus marcas donde el número de clases ha sido obtenido con la regla de la Sturges en Python .

In [6]: `# Cálculo de la amplitud`
`A = round((max(cw)-min(cw))/sturges(cw), 1)`

`print("La amplitud es {}".format(A))`

`# Extremos de los intervalos`
`L = np.zeros(sturges(cw) + 1)`
`L[0] = min(cw) - 1 / 2 * 0.1`
`for i in range(1, sturges(cw) + 1):`
 `L[i] = L[0] + i * A`

`print("Los intervalos son: {}".format(L))`
`# Marcas de clase`

`X = np.zeros(sturges(cw))`
`X[0] = (L[0] + L[1])/2`
`for i in range(1, sturges(cw)):`
 `X[i] = (L[i] + L[i+1])/2`

`print("Las marcas son: {}".format(X))`

La amplitud es 1.4

Los intervalos son: [20.95 22.35 23.75 25.15 26.55 27.95 29.35 30.75 32.15 33.55]

Las marcas son: [21.65 23.05 24.45 25.85 27.25 28.65 30.05 31.45 32.85]

Pregunta 4

Da el algoritmo para reproducir el proceso de generación de clases y sus marcas donde el número de clases ha sido obtenido con la regla de la Freedman-Diaconis en Python .

In [7]: `# Cálculo de la amplitud`
`A = round((max(cw)-min(cw))/freedman_diaconis(cw), 1)`

`print("La amplitud es {}".format(A))`

`# Extremos de los intervalos`
`L = np.zeros(freedman_diaconis(cw) + 1)`
`L[0] = min(cw) - 1 / 2 * 0.1`
`for i in range(1, freedman_diaconis(cw) + 1):`
 `L[i] = L[0] + i * A`

`print("Los intervalos son: {}".format(L))`
`# Marcas de clase`

`X = np.zeros(freedman_diaconis(cw))`
`X[0] = (L[0] + L[1])/2`
`for i in range(1, freedman_diaconis(cw)):`
 `X[i] = (L[i] + L[i+1])/2`

`print("Las marcas son: {}".format(X))`

La amplitud es 1.0

Los intervalos son: [20.95 21.95 22.95 23.95 24.95 25.95 26.95 27.95 28.95 29.95 30.95 31.95 32.95 33.95]

Las marcas son: [21.45 22.45 23.45 24.45 25.45 26.45 27.45 28.45 29.45 30.45 31.45 32.45 33.45]